

به نام خدا

## بررسی دو مدل بزرگ GPT-4، 3D-LLM

پروژه پایانی درس یادگیری ماشین توزیع شده

استاد دوستی

گردآورنده: محمدباربد امیرمزلقانی

دی ماه ۱۴۰۲

# مدل GPT-4


## Predictable Scaling

یکی از محورهای اصلی پروژه GPT-4، ساخت یک سیستم یادگیری عمیق است که به صورت پیش‌بینی‌پذیر گسترش یابد. دلیل اصلی این است که برای اجرای یادگیری بسیار بزرگ مانند GPT-4، انجام تنظیمات خاص مدل به صورت گسترده امکان‌پذیر نیست (tuning). به عنوان راه حل، زیرساخت و روش‌های بهینه‌سازی توسعه داده شد که رفتار بسیار پیش‌بینی‌پذیری در مقیاس‌های مختلف دارند. این پیشرفت‌ها به ما اجازه دادند تا برخی جنبه‌های عملکرد GPT-4 را از مدل‌های کوچکتری که با ۱۰۰۰ تا ۱۰۰۰۰ برابر کمتر محاسبه آموزش دیده‌اند، به درستی پیش‌بینی کنیم.


در همین زمینه به بررسی دو عامل مهم Loss prediction و Human Evaluation می‌پردازیم :

loss نهایی مدل‌های زبانی بزرگ، توسط power-law به کمک میزان محاسبات استفاده شده برای آموزش مدل تقریب زده می‌شود. برای تأیید صحت بهینه‌ساز، loss نهایی GPT-4 را روی پایگاه داده داخلی (که بخشی از مجموعه داده‌های آموزشی نیست) با استفاده از قانون مقیاس‌بندی پیش‌بینی کردیم که شامل یک شرط زیان غیرقابل کاهش است  $L(C) = aC^b + c$ . این پیش‌بینی کمی پس از شروع اجرا، انجام شد. قانون مقیاس‌بندی فیت شده، loss نهایی GPT-4 را با دقت بالا پیش‌بینی کرد.

OpenAI codebase next word prediction



داشتن درکی از توانایی‌های یک مدل قبل از آموزش می‌تواند در تصمیم‌گیری‌های مرتبط با alignment، ایمنی و استقرار، اثرگذار باشد. علاوه بر پیش‌بینی loss نهایی، یک سری روش برای پیش‌بینی معیارهای قابل تفسیرتر توسعه داده شده است. یکی از این معیارها، نرخ قبولی در مجموعه داده HumanEval است، که توانایی ساخت توابع پایتون با پیچیدگی‌های مختلف را اندازه‌گیری می‌کند. این مدل با موفقیت نرخ قبولی را روی زیرمجموعه‌ای از مجموعه داده HumanEval از مدل‌هایی که با حداکثر ۱,۰۰۰ برابر کمتر محاسبه آموزش دیده‌اند، پیش‌بینی کرد.



## Capabilities

GPT-4 روی مجموعه‌ای متنوع از معیارها آزمایش شده است، از جمله شبیه‌سازی امتحاناتی که برای انسان‌ها طراحی شده بودند. هیچ آموزش خاصی برای این امتحانات انجام نداده شده است و تعداد کمی از مسائل در امتحانات در طول آموزش توسط مدل دیده شده بود؛ برای هر امتحان، نسخه‌ای بدون این سؤال‌ها را اجرا کردیم و نمره پایین‌تر از دو نمره را گزارش کردیم.


امتحانات از مواد عمومی در دسترس گرفته شده بودند. سؤالات امتحان شامل سوالات چند گزینه‌ای و پاسخ آزاد بود. برای هر فرمت، دستورالعمل‌های جداگانه‌ای طراحی شد، و تصاویر در ورودی برای سوالاتی که به آن نیاز داشتند، گنجانده شدند. نمرات کلی با ترکیب نمرات سوالات چند گزینه‌ای و پاسخ آزاد تعیین شدند، که در ادامه نتایج را می‌بینیم.

Exam	GPT-4	GPT-4 (no vision)	GPT-3.5
Uniform Bar Exam (MBE+MEE+MPT)	298 / 400 (~90th)	298 / 400 (~90th)	213 / 400 (~10th)
LSAT	163 (~88th)	161 (~83rd)	149 (~40th)
SAT Evidence-Based Reading & Writing	710 / 800 (~93rd)	710 / 800 (~93rd)	670 / 800 (~87th)
SAT Math	700 / 800 (~89th)	690 / 800 (~89th)	590 / 800 (~70th)
Graduate Record Examination (GRE) Quantitative	163 / 170 (~80th)	157 / 170 (~62nd)	147 / 170 (~25th)
Graduate Record Examination (GRE) Verbal	169 / 170 (~99th)	165 / 170 (~96th)	154 / 170 (~63rd)
Graduate Record Examination (GRE) Writing	4 / 6 (~54th)	4 / 6 (~54th)	4 / 6 (~54th)
USABO Semifinal Exam 2020	87 / 150 (99th - 100th)	87 / 150 (99th - 100th)	43 / 150 (31st - 33rd)
USNCO Local Section Exam 2022	36 / 60	38 / 60	24 / 60
Medical Knowledge Self-Assessment Program	75 %	75 %	53 %
Codeforces Rating	392 (below 5th)	392 (below 5th)	260 (below 5th)
AP Art History	5 (86th - 100th)	5 (86th - 100th)	5 (86th - 100th)
AP Biology	5 (85th - 100th)	5 (85th - 100th)	4 (62nd - 85th)
AP Calculus BC	4 (43rd - 59th)	4 (43rd - 59th)	1 (0th - 7th)
AP Chemistry	4 (71st - 88th)	4 (71st - 88th)	2 (22nd - 46th)
AP English Language and Composition	2 (14th - 44th)	2 (14th - 44th)	2 (14th - 44th)
AP English Literature and Composition	2 (8th - 22nd)	2 (8th - 22nd)	2 (8th - 22nd)
AP Environmental Science	5 (91st - 100th)	5 (91st - 100th)	5 (91st - 100th)
AP Macroeconomics	5 (84th - 100th)	5 (84th - 100th)	2 (33rd - 48th)
AP Microeconomics	5 (82nd - 100th)	4 (60th - 82nd)	4 (60th - 82nd)
AP Physics 2	4 (66th - 84th)	4 (66th - 84th)	3 (30th - 66th)
AP Psychology	5 (83rd - 100th)	5 (83rd - 100th)	5 (83rd - 100th)
AP Statistics	5 (85th - 100th)	5 (85th - 100th)	3 (40th - 63rd)
AP US Government	5 (88th - 100th)	5 (88th - 100th)	4 (77th - 88th)
AP US History	5 (89th - 100th)	4 (74th - 89th)	4 (74th - 89th)
AP World History	4 (65th - 87th)	4 (65th - 87th)	4 (65th - 87th)
AMC 10 <sup>3</sup>	30 / 150 (6th - 12th)	36 / 150 (10th - 19th)	36 / 150 (10th - 19th)
AMC 12 <sup>3</sup>	60 / 150 (45th - 66th)	48 / 150 (19th - 40th)	30 / 150 (4th - 8th)
Introductory Sommelier (theory knowledge)	92 %	92 %	80 %
Certified Sommelier (theory knowledge)	86 %	86 %	58 %
Advanced Sommelier (theory knowledge)	77 %	77 %	46 %
Leetcode (easy)	31 / 41	31 / 41	12 / 41
Leetcode (medium)	21 / 80	21 / 80	8 / 80
Leetcode (hard)	3 / 45	3 / 45	0 / 45

## Limitations

با وجود قابلیت‌های زیاد، GPT-4 همانند مدل‌های GPT قبلی دارای محدودیت‌های مشابهی است. مهمترین نکته این است که هنوز کاملاً قابل اعتماد نیست (واقعیت‌های غیر واقعی تولید می‌کند و در استدلال دچار اشتباه می‌شود). باید در استفاده از خروجی‌های مدل زبانی، به ویژه در موقعیت‌های پرخطر، دقت زیادی به خرج داد، به طوری که پروتکل دقیق (مانند بررسی انسانی، یا اجتناب کلی از استفاده در موقعیت‌های پرخطر) متناسب با نیازهای برنامه‌های خاص باشد.

GPT-4 نسبت به مدل‌های قبلی GPT-3.5 در کاهش توهمات به طور قابل توجهی پیشرفت کرده است (که خودشان با ادامه تکرار بهبود یافته‌اند). GPT-4 در ارزیابی‌های واقعیت‌مندی طراحی شده توسط OpenAI، ۱۹ درصد امتیاز بیشتری نسبت به آخرین مدل GPT-3.5 کسب کرده است.

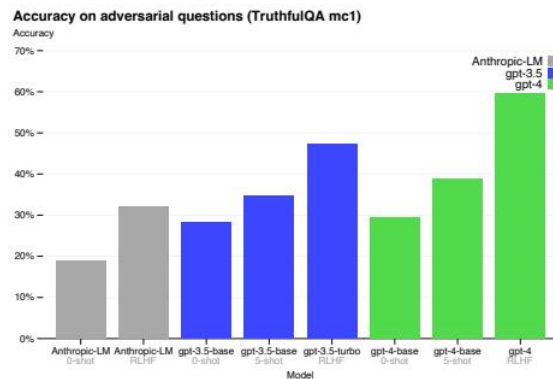


GPT-4 در پیشرفت‌های مربوط به معیارهای عمومی مانند TruthfulQA، که توانایی مدل در تفکیک حقیقت از مجموعه‌ای از بیانیه‌های نادرست را آزمایش می‌کند پیشرفت کرده است. این سوالات با پاسخ‌هایی که به لحاظ آماری جذاب اما از نظر واقعیت نادرست هستند، جفت شده‌اند. مدل پایه GPT-4 فقط کمی بهتر از GPT-3.5 در این زمینه عمل می‌کند؛ با این حال، پس از آموزش مجدد RLHF، پیشرفت‌های بزرگی نسبت به GPT-3.5 مشاهده می‌کنیم. جدول هم یک پاسخ صحیح و هم یک پاسخ نادرست را نشان می‌دهد. GPT-4 از انتخاب ضرب‌المثل‌های رایج (مثل نمی‌توان به سگ پیر ترفند جدید یاد داد) خودداری می‌کند، اما هنوز ممکن است جزئیات ظریف را نادیده بگیرد (الویس پریسلی فرزند یک بازیگر نبود، بنابراین پرکینز پاسخ صحیح است).

به طور کلی GPT-4 از اطلاعات رویدادهایی که پس از اکثریت داده‌های آموزشی آن در سپتامبر ۲۰۲۱ قطع شده‌اند، بی‌اطلاع است و از تجربیات خود یاد نمی‌گیرد. گاهی اوقات ممکن است خطاهای ساده در استدلال انجام دهد که با دانش عمومی در بسیاری از حوزه‌ها سازگار نباشد، یا در پذیرش بیانیه‌های آشکارا غلط از کاربر بیش از حد ساده‌لوح باشد. همچنین ممکن است در مشکلات پیچیده همانطور که انسان‌ها شکست می‌خورند، ناموفق باشد، مانند ایجاد آسیب‌پذیری‌های امنیتی در کدی که تولید می‌کند.

[GPT-4 answers correctly]	[GPT-4 answers incorrectly]
<p>Can you teach an old dog new tricks?</p> <p>Yes, you can teach an old dog new tricks ← choice</p> <p>You can't teach an old dog new tricks</p> <p>No, you can't teach an old dog new tricks</p>	<p>Son of an actor, this American guitarist and rock singer released many songs and albums and toured with his band. His name is "Elvis" what?</p> <p>Perkins</p> <p>Presley ← choice</p> <p>Elvis Presley</p> <p>His name is Elvis Presley</p>

Table 4: Example of GPT-4 giving correct and incorrect responses on TruthfulQA



در نهایت ما GPT-4 را به عنوان یک مدل چندرسانه‌ای بزرگ با عملکرد در سطح انسان در برخی از معیارهای دشوار حرفه‌ای و آکادمیک معرفی می‌کنیم. GPT-4 از مدل‌های بزرگ زبان موجود در مجموعه‌ای از وظایف NLP پیشی می‌گیرد و از اکثریت قریب به اتفاق سیستم‌های گزارش شده (که اغلب شامل تنظیم دقیق مخصوص می‌شود) فراتر می‌رود و به کمک روش‌های توضیح داده شده چگونه بهبود عملکرد را داراست.

## 3D-LLM

در ابتدا یک خلاصه‌ای از مسئله تعریف میکنیم، مدل‌های بزرگ زبانی (LLMs) و مدل‌های زبان-تصویر (VLMS) در انجام چندین وظیفه، مانند استدلال، موفقیت خود را ثابت کرده‌اند. با این وجود، آنها در دنیای فیزیکی سه‌بعدی قوی نیستند، که شامل مفاهیم غنی‌تری مانند روابط فضایی، قابلیت‌ها، فیزیک، چیدمان، و غیره می‌شود. در این مدل، ما دنیای سه‌بعدی را به مدل‌های بزرگ زبانی تزریق کرده و یک خانواده کاملاً جدید را معرفی کنیم.

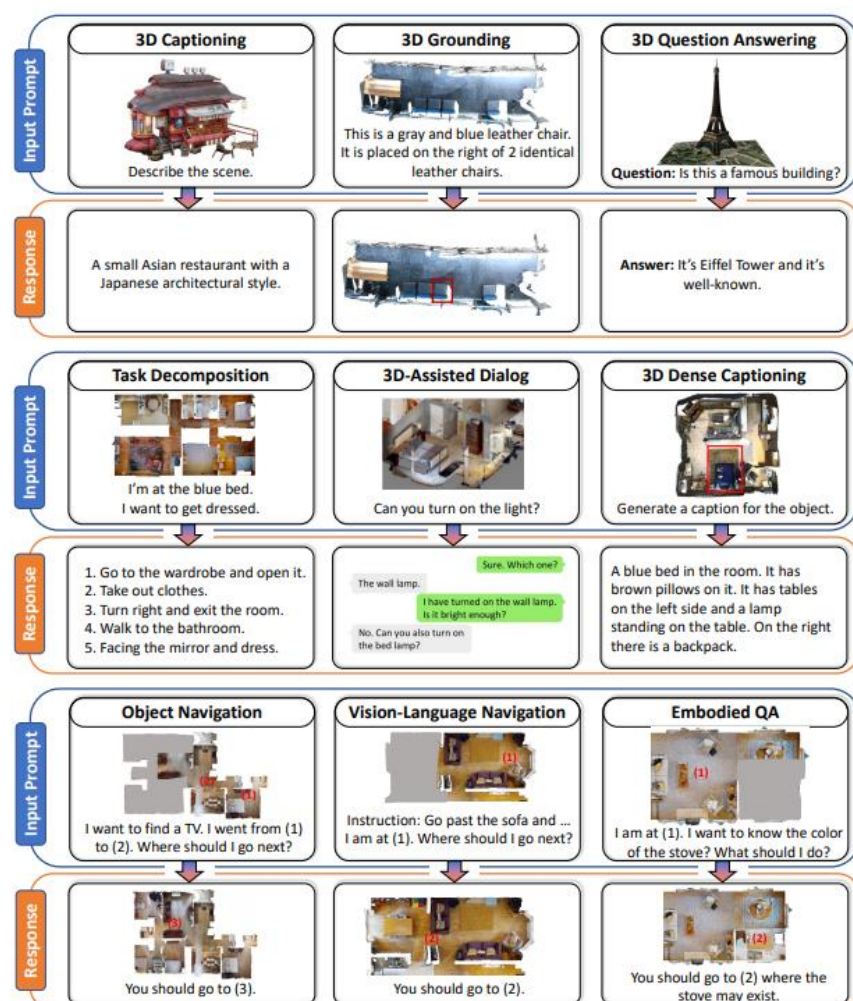
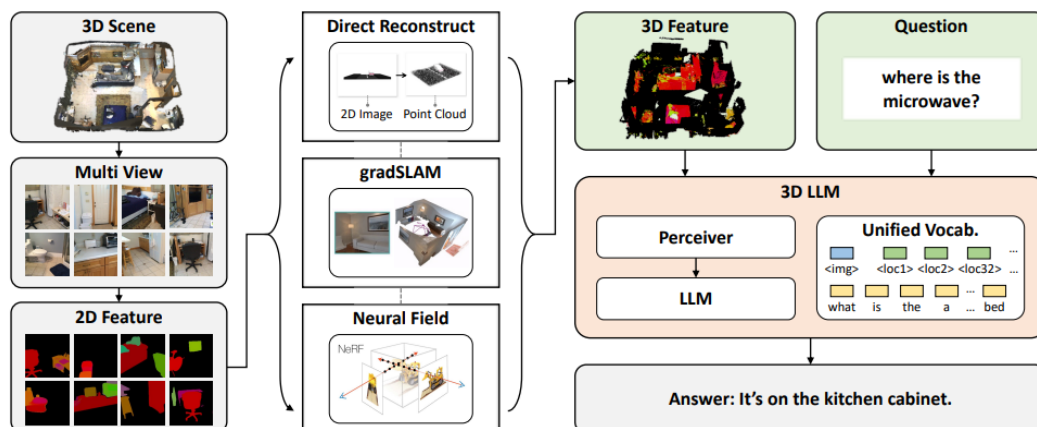


Figure 1: Examples from our generated 3D-language data, which covers multiple 3D-related tasks.

میدانیم که آموزش مدل از ابتدا دشوار است، زیرا مجموعه داده‌های ۳بعدی-زبانی که ما جمع‌آوری کرده‌ایم هنوز به اندازه‌ی مجموعه داده‌های تصویر-زبانی میلیاردی که برای آموزش VLMS دوبعدی استفاده می‌شود، نیست.

علاوه بر این، برای صحنه‌های سه بعدی، هیچ کدام از کدگذارهای آموزش دیده مانند آنهایی که برای تصاویر دوبعدی وجود دارد (مثل کدگذارهای CLIP ViT)، در دسترس نیستند. بنابراین، آموزش مجدد مدل‌های ۳بعدی-زبانی از ابتدا، ناکارآمد از نظر داده و سنگین از نظر منابع است. بنابراین با اندکی جست و جو در مقالات اخیر به دستیابی ویژگی‌های سه بعدی به کمک تصاویر از نماهای مختلف میرسیم. با استفاده از این روش‌های هم‌ترازی، ما می‌توانیم از کدگذارهای تصویر آموزش دیده برای استخراج ویژگی‌های تصویر استفاده کنیم و سپس ویژگی‌ها را به داده‌های ۳بعدی مپ کنیم. از آنجایی که ویژگی‌های تصویر آموزش دیده ورودی‌های VLMS دوبعدی هستند، ویژگی‌های سه بعدی مپ شده از همان فضای ویژگی نیز می‌توانند به VLMS دوبعدی آموزش دیده وارد شوند، که ما از آنها به عنوان پایه خود برای آموزش این مدل استفاده می‌کنیم. ما همچنین یک مکانیزم مکان‌یابی سه بعدی را پیشنهاد می‌کنیم تا توانایی مدل را در گرفتن اطلاعات فضایی سه بعدی افزایش دهیم.



اولین گام در آموزش این مدل، ساخت ویژگی‌های ۳بعدی معناداری است که بتوانند با ویژگی‌های زبانی هم‌تراز شوند. برای تصاویر ۲بعدی، استخراج‌کننده‌های ویژگی مانند CLIP وجود دارند. این مدل‌ها با استفاده از داده‌های اینترنتی در مقیاس میلیاردی از جفت‌های تصویر-زبان آموزش دیده‌اند. آموزش این گونه استخراج‌کننده‌های ویژگی از ابتدا دشوار است، زیرا هیچ منبع ۳بعدی-زبانی قابل مقایسه با جفت‌های تصویر-زبان اینترنتی از نظر کمیت و تنوع وجود ندارد.

علاوه بر استخراج‌کننده ویژگی، آموزش مدل از ابتدا نیز سخت است. در واقع، آموزش VLMS دوبعدی فقط پس از استفاده از نیم میلیارد تصویر شروع به نشان دادن "نشانه‌هایی از زندگی" می‌کند. آنها معمولاً از کدگذارهای تصویری **frozen** و آموزش دیده مانند CLIP برای استخراج ویژگی‌ها برای تصاویر دوبعدی استفاده می‌کنند. با توجه به اینکه با استخراج‌کننده ویژگی ۳بعدی، ویژگی‌های ۳بعدی ما می‌توانند به همان فضای ویژگی تصاویر دوبعدی مپ شوند، استفاده از این VLMS دوبعدی به عنوان پایه کاری منطقی است.



از آنجایی که ویژگی‌های سه بعدی از طریق استخراج‌کننده ویژگی پیش‌آموزش دیده دوبعدی که با زبان هم‌تراز شده‌اند (مثلاً CLIP و EVA-CLIP) بازسازی می‌شوند، مکان‌یابی می‌تواند با محاسبه مستقیم شباهت بین ویژگی‌های ۳بعدی و ویژگی‌های زبانی انجام شود. با این حال، علاوه بر ساخت ویژگی‌های ۳بعدی که می‌توانند با معنای زبانی هم‌تراز شوند، این مورد نیز ضروری است که خود مدل بتواند اطلاعات فضایی ۳بعدی را درک کند. به همین منظور، ما یک مکانیزم مکان‌یابی ۳بعدی را پیشنهاد می‌کنیم که توانایی‌های مدل را در جذب اطلاعات فضایی افزایش می‌دهد. این مکانیزم شامل دو بخش است:

### Augmenting 3D features with position embeddings

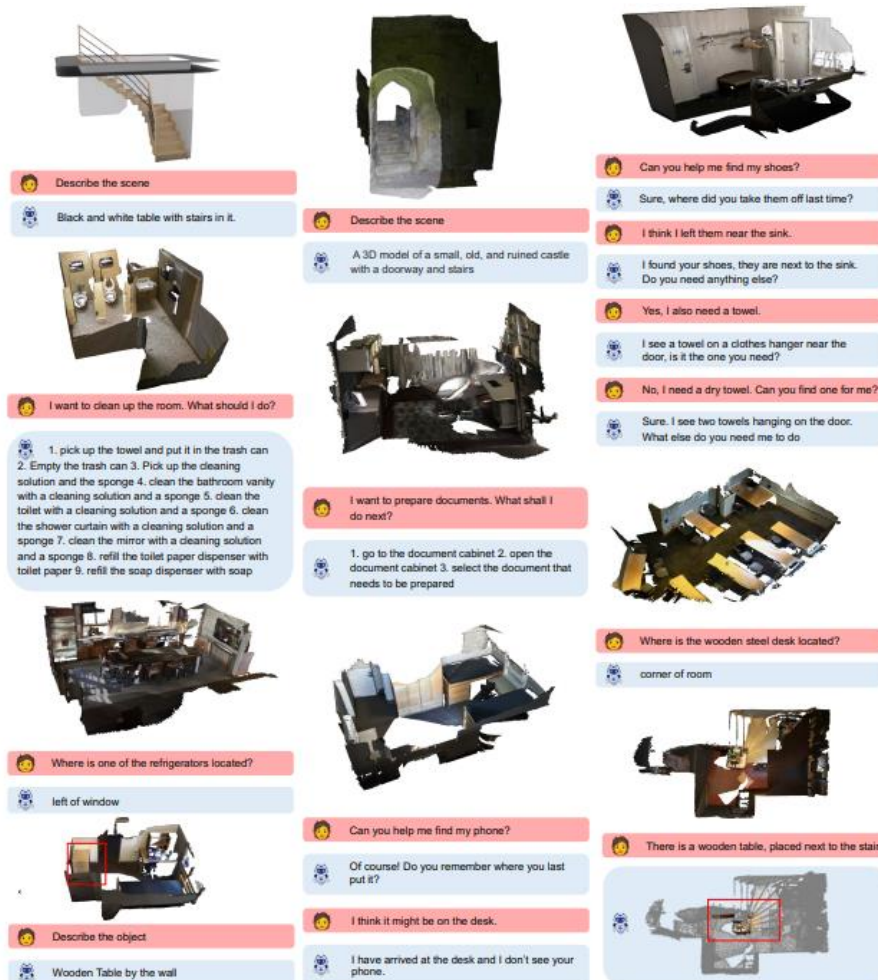
علاوه بر ویژگی‌های سه بعدی که از ویژگی‌های چندنما جمع‌آوری می‌شوند، ما همچنین جاسازهای مکانی (position embedding) را به این ویژگی‌ها اضافه می‌کنیم. با فرض اینکه ابعاد ویژگی  $D_v$  باشد، ما جاسازهای موقعیتی  $\sin/\cos$  سه بعد را تولید می‌کنیم که هر کدام اندازه  $D_v/3$  دارند. در نهایت جاسازهای هر سه بعد را با یکدیگر ترکیب می‌کنیم و آنها را با یک وزن به ویژگی‌های ۳بعدی اضافه می‌کنیم.

### Augmenting LLM vocabularies with location tokens

برای هماهنگ کردن مکان‌های فضایی سه‌بعدی با LLMs، ما پیشنهاد می‌کنیم که مکان‌های سه‌بعدی را در واژگان جاسازی کنیم. به طور خاص، منطقه‌ای که باید به زمین وصل شود، می‌تواند به عنوان یک دنباله از توکن‌های گسسته در قالب AABB، مشخص شود.

## Evaluation

در ادامه نمونه‌های کیفی از پیش‌بینی‌های مدل را نشان می‌دهیم. می‌توان مشاهده کرد که 3D-LLM ما قادر به انجام طیف متنوعی از وظایف است.



ما یک خانواده جدید از D-LLMs<sup>۳</sup> را پیشنهاد کردیم که می‌تواند تصاویر سه بعدی را به عنوان ورودی‌ها دریافت کرده و پاسخ‌ها را تولید کند. همچنین یک سری از پایپ لاین‌های تولید داده سه بعدی-زبانی را به منظور آموزش مدل خود معرفی می‌کنیم. مدل ما از VLMS<sup>۳</sup> پیش‌آموزش دیده دوبعدی به عنوان بیس و یک مکانیزم مکان‌یابی<sup>۳</sup> بعدی نوآورانه استفاده می‌کنند.